Dokumentace úlohy XTD: XML2DDL v Pythonu do IPP 2011/2012

Jméno a příjmení: Vojtěch Dlápal

Login: xdlapa01

Úvod

Úlohou je převést vstupní soubor ve formátu XML na sekvenci DDL příkazů s dalšími požadavky danými vstupními parametry. Zvolený jazyk Python dovoluje využívat jak objektově orientovaného paradigmatu, tak strukturovaného programování a k tomu bylo přihlíženo při návrhu. Také byl brán ohled na možnosti zvolených knihoven.

Zpracování vstupních parametrů

Zpracování parametrů probíhá pomocí knihovny argparse. Tato knihovna nabízí velmi jednoduché přidávání parametrů, ale pro potřeby projektu bylo nutné práci s touto knihovnou rozšířit o jiné nastavení návratových kódů a ošetření unikátnosti parametru --help.

Zpracování vstupního souboru

Pro zpracování vstupního XML byla zvolena knihovna xml.etree.ElementTree. Ta vytvoří strom z jednotlivých XML elementů a tím je pak postupně iterováno, přičemž pro každého rodiče se vytvoří seznam potomků a dvojice rodič-seznam potomků jsou uchovávány v datovém typu slovník, přičemž pro každý další stejný element jsou do seznamu potomků přidávány pouze ty podelementy, které jsou v kontextu předchozích výskytů navíc.

Dále se pro každý element vytvoří instance třídy Table a jsou naplněny atributy této třídy podle atributů příslušného elementu.

Třída Table

Třída Table je umístěna v samostatném modulu table v balíku modules. Reprezentuje tabuku databáze. Její gettery a settery upravují jednotlivé atributy do požadovaného formátu. Uchovává v sobě jméno dané tabulky, seznam cizích klíčů, slovník atribut:hodnota, dále pro omezování počtu podelementů při generování cizích klíčů v sobě nese také toto omezení jako hodnotu etc, pro potřebu přidání cizího klíče předka objekt s předkem a posledním atributem je příznak pro generování klíče z předka. Metoda getTableStr() vrací řetězec DDL v požadovaném formátu reprezentující danou tabulku.

Dále modul table obsahuje funkci pro získání datového typu. To je prováděno pomocích regulárních výrazů. Tato funkce je volána z metody tabulky pro získání atributů a textových hodnot pro každý atribut zvlášť a její návratová hodnota, kterou je řetězec s názvem datového typu je porovnávána s předchozími atributy podle priorit.

Výstup

Formát výstupu se řídí především podle vstupních parametrů. Pokud je zadán parametr s hlavičkou, je jako první úkon proveden výpis této hlavičky. Pro tisk jednotlivých tabulek se iteruje přes slovník mající jako hodnoty instance třídy Table a do výstupního proudu je posílán řetězec získaný metodou getTableStr(). Na základě parametru -a je při iteraci stromem elementů přeskočeno nastavování atributů, a proto se negenerují. Podobným způsobem parametr –b omezí počet generovaných podelementů na jediný.

.